

PWA · ESCUDO EN TIEMPO REAL

NADA

Amores y Traiciones

Detección de fraude conversacional y manipulación en apps de citas y mensajería. Texto, voz, imagen y videollamada.

EL PROBLEMA

Nadie cae por ingenuo. Cae porque el fraude llega dentro de una conversación que quiere tener.

- Cuando alguien empieza a dudar, **ya está emocionalmente comprometido**.
- Preguntar a un familiar da vergüenza, así que no se pregunta.
- El aviso llega cuando el dinero ya salió: entonces sirve para el atestado, no para la persona.

La FTC de EE. UU. reporta más de mil millones de dólares anuales en pérdidas por estafa sentimental. Cifra pública ampliamente difundida; no verificada por este equipo.

EL PROBLEMA REAL

No era detectar más. Era detectar **sin molestar**.

Un detector con falsos positivos entrena a su usuario a ignorarlo. Y una alerta que nadie cree no protege a nadie el día que es verdad.

Problema A — falsos positivos

El diccionario evaluaba palabras aisladas, no contexto. «Mi amor, ¿me mandas 800 dólares?» es una madre escribiéndole a su hijo.

Problema B — inyección de prompt

El texto que analizamos lo escribe el atacante. Puede intentar hablarle a nuestra propia IA y desactivarla.

LAS DOS REGLAS DEL PRODUCTO

Lo que NADA no hará nunca

REGLA 1

Nunca dice «esta persona es un estafador»

Emite indicadores de riesgo, cada uno con su confianza y su motivo. Quien decide es la persona. Un veredicto binario sobre alguien real es una acusación, y equivocarse tiene víctima.

REGLA 2

Ninguna alerta salta por una señal aislada

Hace falta corroboración de dos fuentes independientes, en una ventana deslizante de 30 segundos. Es la regla que compra el 0 % de falsas alarmas.

Única excepción ética: la inducción al suicidio o la autolesión alerta sola.

Qué se queda en el móvil y qué sale

ON-DEVICE

No sale del dispositivo

Malla facial, parpadeo, pose, rPPG, detección de bucle, voz sintética y transcripción.

Ningún frame ni audio crudo se transmite ni se persiste.

NUBE

Sólo texto

El análisis de lenguaje va a Gemini, Groq, Venice, Claude o Bedrock. Texto no es dato biométrico. Es opcional: sin claves, el análisis local funciona igual.

CÓDIGO PROPIO

La decisión

Los modelos emiten una **señal**: puntuación y confianza. La fusión y el veredicto los calcula código determinista. **Nunca decide un LLM.**

No es un ajuste que se pueda cambiar luego: el reporte de vídeo no tiene ningún campo donde meter un frame, y el servidor lo descarta aunque la petición lo traiga. Hay un test que lo comprueba.

LA IDEA TÉCNICA

Una estafa tiene **forma**, no palabras clave

FRASE SUELTA

«Ve al Banco Azteca»

«No cuelgues, quédate en la línea»

«Tengo a tu muchacho»

Las tres juntas

¿SOSPECHOSA SOLA?

No. Es un banco real.

No. Se lo dices a tu madre.

No necesariamente.

Secuestro virtual.

72 patrones en 25 categorías y 26 reglas de combinación, en español, inglés y portugués, contruidos sobre campañas reales publicadas por **INCIBE**. Cada señal suelta pesa por debajo del umbral *a propósito*.

El texto analizado lo escribe el atacante

- **No existe la costura donde concatenar.** Las reglas van en el turno `system` y el mensaje en el `user`, entre marcadores con identificador aleatorio por petición.
- **Se escanea en seis vistas** —plana, leet, espaciada, invertida, base64, rot13— y el disfraz suma en vez de esconder.
- **Aunque un modelo caiga del todo, no decide.** Sólo puede empujar una fuente entre varias.
- **Los reportes de usuarios nunca tocan el corpus** contra el que se mide una regla nueva. Si se juntaran, el atacante escribiría el examen con el que se le juzga. Hay un test que impide ese cableado.

Protocolo completo mapeado a MITRE ATLAS y NIST AI RMF en `docs/PROTOCULO-SEGURIDAD.md`.

RESULTADOS MEDIDOS · REPRODUCIBLES CON UNA ORDEN

Detección sobre 65 casos etiquetados

MÉTRICA	AL EMPEZAR	HOY
Acierto exacto	34,1 %	83,1 %
Amenazas detectadas	35,3 %	87,5 %
Falsas alarmas	0 %	0 %
Fallos graves	14	0

40/40

ataques de inyección detectados,
con 0 falsas alarmas sobre
conversación normal

490

tests automáticos; la batería de
seguridad corre también contra
PostgreSQL real

0 %

de falsas alarmas: la cifra que
más costó y la que más importa

HONESTIDAD

Lo que NADA **no** hace

- No dicta veredictos ni bloquea a nadie.
- No sube fotos ni audio a ningún servidor.
- No detecta lo que no ha visto: el corpus tiene 65 casos, no todas las estafas del mundo.
- La detección de deepfake es una heurística biométrica, no un modelo entrenado contra deepfakes reales. Por eso la recomendación es «verifica por otro canal», no «es falso».
- La batería de ataques la escribió quien escribió las defensas: mide cobertura de lo previsto, no resistencia a lo imprevisto.

Decir esto en voz alta genera más confianza que sobrevender. Y es coherente con la Regla 1.

Gratis lo que protege. De pago lo que amplía.

Gratis, sin cuenta y sin red

Detección local completa. Quien más lo necesita no va a pagar antes de confiar, y una barrera de pago delante de la protección deja fuera justo a quien la necesita.

De pago

IA en la nube para fraseo nunca visto, histórico de conversaciones y panel para familias.

B2B

Apps de citas y bancos, que hoy pagan el fraude que no supieron ver a tiempo. API del motor de fusión.

Cifras de precio pendientes de validar con mercado: se presentan como propuesta razonada, no como dato.

NADA no bloquea a nadie ni dicta veredictos.
Le da a la persona el dato que le falta,
en el momento en que le sirve.

github.com/wnivia-v/NADA-AMORES-Y-TRAICIONES · `npm ci && npm run dev`